МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«ДОНСКОЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»
(ДГТУ)

ОТЧЁТ

по лабораторной работе № 6
«Исследование параметров text-to-image генерации»
по дисциплине: «Искусственный интеллект в креативных технологиях»

Вариант 10

Обложка подкаста о городской среде * короткий и структурированный запрос

Выполнил: Павленко Степан Андреевич
Группа: МИМО11
Дата выполнения: 5 ноября 2026 г.

Ростов-на-Дону
2026

1. Цель, постановка задачи и гипотеза

1.1. Цель работы

Цель работы - определить влияние структуры текстового запроса на результаты генерации изображений моделью SD Turbo при фиксированных остальных параметрах. Оценка проводится по соответствию исходному брифу, энергии границ, контрасту и времени генерации на серии из пяти начальных значений генератора (seed).

1.2. Индивидуальное задание

Вариант N = 10 соответствует второму брифу (обложка подкаста о городской среде) и четвёртому фактору: замена короткого запроса структурированным. Оба режима используют один шаг диффузии, guidance_scale = 0,0, размер 512 x 512 и seed 101, 102, 103, 104, 105.

Компонент	Режим A	Режим B
Текст запроса	Короткий: только предмет	Структурированный: предмет, композиция, палитра, стиль, ограничения
Модель	SD Turbo	SD Turbo
Параметры	1 шаг, CFG 0,0, 512 x 512	1 шаг, CFG 0,0, 512 x 512
Seed	101-105	101-105

1.3. Гипотеза и допуски до запуска

Гипотеза, сохранённая в файле before_run.txt до начала эксперимента: структурированный запрос повысит сходство с полным исходным брифом по CLIP. Практические допуски заданы заранее: для CLIP ±1,0 балла; для энергии границ и контраста ±10% от среднего режима A; для времени генерации ±20%.

Отдельно используется учебный критерий $|\Delta| > 2s$, где s - выборочное стандартное отклонение по режиму A. Он служит индикатором выхода изменения за уровень разброса между seed, но не заменяет оценку практической пользы.

2. Теоретические основы и метрики

SD Turbo - дистиллированная text-to-image модель, способная генерировать изображения за малое число шагов. В рекомендованном режиме используется guidance_scale = 0,0. Сравнивая запросы, необходимо сохранить неизменными модель, размеры и прочие параметры генерации.

Метрика	Метод расчёта	Интерпретация
CLIP	100 * cos(e_image, e_text) для исходного полного английского брифа	Больше - лучше соответствие брифу; не измеряет эстетику
Энергия границ (edge)	Средний модуль градиента яркости, Собель / 8	Большие значения отражают больше границ, в т.ч. артефактов
Контраст	Стандартное отклонение яркости Y	Больше - шире распределение яркости, не обязательно лучше
Время, с	Время одного вызова генерации без загрузки модели	Меньше - быстрее; зависит от состояния GPU

CLIP оценивает оба режима относительно одного и того же полного английского брифа. Если для режима A использовать короткий текст как эталон, измерения окажутся несопоставимыми.

3. Исходные данные, модели и среда

3.1. Тексты запросов

Режим A:

```
podcast cover about the city
```

Режим B:

```
square podcast cover about the city environment, abstract layered skyline of geometric shapes, teal and orange palette, minimal flat style, no text, no people
```

Тексты являются синтетическими учебными брифами. Не использовались фотографии реальных людей, реальные логотипы или чужие материалы. Изображения не выдаются за фотографию конкретного города.

3.2. Среда и версии

Параметр	Фактическое значение
Платформа	Google Colab, Linux
GPU	Tesla T4
Python	3.13.16
PyTorch	2.11.0+cu130
Diffusers	0.40.0
Transformers	5.16.1
Pillow / SciPy	11.3.0 / 1.16.3
Генератор	torch.Generator(device="cpu"), seed 101-105
Точность модели	float16

3.3. Модели и лицензии

Модель генерации: stabilityai/sd-turbo, ревизия b261bac6fd2cf515557d5d0707481eafa0485ec2. Лицензия закреплённой ревизии: Stability AI Community License Agreement от 05.07.2024. В данной работе использован некоммерческий учебный режим; при другом использовании необходимо учитывать условия лицензии и политики допустимого использования.

Оценочная модель: openai/clip-vit-base-patch32, ревизия 3d74acf9a28c67741b2f4f2ea7635f0aaf6f0268. CLIP используется только для исследовательского сравнения текста и изображений. Карточка модели отмечает ограничения обобщения, в частности для языков вне английского и для прикладных решений без отдельной проверки. Условия распространения исходного кода CLIP приведены в репозитории проекта OpenAI; при повторном применении следует сверять условия конкретных весов.

4. Ход выполнения

В отдельном блокноте Google Colab записаны библиотеки lab05_lib.py и lab06_lib.py. Загружены SD Turbo и CLIP, выполнен демонстрационный вариант 1, затем основной эксперимент по варианту 10. Два режима прогревались до серии измерений, после чего выполнялись парные запуски A и B для одинаковых seed.

```
import lab05_lib as L
import lab06_lib as M
N = 10
pipe = L.load_pipe()
clip = M.load_clip()
res = M.variant_summary(pipe, clip, N)
```

Для каждой метрики вычислены среднее A, выборочное стандартное отклонение s режима A, среднее B, разность Δ = B - A, отношение |Δ| / s и признак |Δ| > 2s. Отдельно создан сравнительный лист для seed 101 и выполнена проверка параметра guidance_scale.

5. Результаты эксперимента

5.1. Сводная таблица по пяти seed

Метрика	Среднее A	s (A)	Среднее B	Δ = B - A	|Δ|/s	> 2s
CLIP	23,0601	0,9941	34,0965	+11,0364	11,10	Да
Энергия границ	0,0628	0,0170	0,0417	-0,0212	1,25	Нет
Контраст	0,1851	0,0200	0,1673	-0,0178	0,89	Нет
Время, с	0,2786	0,0082	0,2746	-0,0041	0,50	Нет

5.2. Практическая классификация

Метрика	Изменение относительно A	По допуску	По критерию 2s
CLIP	+47,9% (+11,0364)	Существенный рост	Изменение заметно
Энергия границ	-33,7%	Изменение за пределами ±10%	Не превышает порог
Контраст	-9,6%	Нейтрально (предел ±10%)	Не превышает порог
Время генерации	-1,5%	Нейтрально (предел ±20%)	Не превышает порог

В отличие от CLIP, снижение энергии границ не достигает критерия 2s (|Δ| / s = 1,25), хотя по заранее установленному практическому допуску изменение велико (около -33,7%). Рост или падение энергии границ само по себе не означает повышение или снижение эстетического качества изображения.

5.3. Сравнительный лист (seed 101)



Рисунок 1 - Изображения по короткому (слева) и структурированному (справа) запросам, seed 101

На изображении A видна более реалистичная городская панорама; присутствуют похожая на заголовок надпись и декоративная круглая эмблема, хотя они не задавались коротким запросом. В режиме B выражены геометрические слои и бирюзово-оранжевая палитра, соответствующие исходному брифу; заметного читаемого текста нет. Визуальная оценка выполнена только для seed 101 и не подменяет статистику пяти запусков.

6. Анализ результатов

6.1. Интерпретация метрик

Соответствие брифу по CLIP увеличилось с 23,0601 до 34,0965 (Δ = +11,0364). Разность более чем в 11 раз превышает s режима A, поэтому эффект по учебному критерию 2s заметен и существенно превосходит практический допуск ±1,0. Это согласуется с гипотезой о пользе структурированного промпта для реализации заданных деталей.

Энергия границ уменьшилась с 0,0628 до 0,0417, то есть на 33,7%. Изменение больше практического порога ±10%, но меньше 2s. Возможное объяснение - изменение композиции и распределения деталей между режимами. Без дополнительного анализа нельзя делать вывод об ухудшении визуального качества только по метрике Собеля.

Контраст снизился с 0,1851 до 0,1673 (9,6%); это укладывается в допуск ±10% и не превышает 2s. Среднее время генерации практически не изменилось: 0,2786 с против 0,2746 с (около 1,5% быстрее), что укладывается в допуск ±20% и подвержено колебаниям загрузки GPU.

6.2. Статистическая заметность и практическая польза

По двум критериям согласован только CLIP: изменение заметно по 2s и выходит за допуск. Для энергии границ критерии расходятся: практическая разница велика, но разброс между seed не позволяет квалифицировать её как устойчивый эффект по правилу 2s. Для контраста и времени оба критерия говорят об отсутствии существенного эффекта. Данный учебный критерий не является строгим статистическим тестом и не даёт p-значения.

7. Намеренно введённая ошибка guidance_scale

Проверялось неверное ожидание, что guidance_scale = 1,0 включает classifier-free guidance у SD Turbo. Для одного брифа и seed 101 получен одинаковый SHA-256 при guidance_scale 0,0 и 1,0; признак do_classifier_free_guidance равен False. При guidance_scale = 3,0 признак стал True; PSNR относительно результата при 0,0 составил 10,89 дБ.

```
    x0 = L.generate(pipe, L.BRIEFS[1], 101, guidance=0.0)[0]
x1 = L.generate(pipe, L.BRIEFS[1], 101, guidance=1.0)[0]
print(L.sha(L.png_bytes(x0)) == L.sha(L.png_bytes(x1))) # True
# При guidance=3.0 CFG включается; PSNR к x0 = 10.89 дБ
```

Следовательно, при guidance_scale <= 1 в данном конвейере CFG не активируется. SD Turbo рекомендуется использовать с guidance_scale = 0,0; результат не следует переносить на другие модели и реализации без дополнительной проверки.

8. Ограничения и угрозы валидности

Эксперимент выполнен для одного брифа, одной модели, одного GPU и пяти seed. Оценка CLIP не измеряет художественное качество и может зависеть от набора данных, на которых обучена модель. Поскольку CLIP вычислялся относительно полного английского брифа, подробный запрос содержательно ближе к тексту эталона: это осознанная часть схемы эксперимента, но не доказательство универсального превосходства сложных запросов. Энергия границ и контраст чувствительны к композиции; выводы о времени ограничены условиями конкретного сеанса Colab.

Для проверки устойчивости вывода полезно расширить серию seed, выполнить независимую экспертную оценку изображений и протестировать другие брифы. Результаты корректны только в рамках данных параметров и не доказывают, что более подробный запрос всегда улучшает генерацию.

9. Вывод по работе

Цель лабораторной работы достигнута: экспериментально оценено влияние структуры запроса при фиксированных настройках SD Turbo. Структурированный запрос для обложки подкаста о городской среде повысил соответствие исходному брифу по CLIP на 11,0364 балла (примерно на 47,9%). Энергия границ снизилась, но по критерию 2s эффект не подтверждён; контраст и время практически не изменились. Подтверждена необходимость отличать соответствие брифу от эстетического качества, а статистическую заметность от практического допуска.

10. Паспорт эксперимента и приложенные артефакты

Параметр	Значение
Среда	Google Colab, Tesla T4, 3.13.16
Модель и ревизия	SD Turbo, b261bac6fd2cf51...
Модель метрики	CLIP ViT-B/32, 3d74acf9a28c677...
Размер / шаги / guidance	512 x 512 / 1 / 0,0
Seed / количество	101-105 / 5
Дата выполнения	05.11.2026, около 14:53 (время журнала Colab)
Блокнот	ЛР06_вариант_10_Colab.ipynb, 9 выполненных ячеек
Дополнительные файлы	LR06_results.zip: metrics.csv, passport.json, comparison.png, A_seed101.png, B_seed101.png, before_run.txt

Индивидуальный вклад: выполнение эксперимента по назначенному варианту 10, фиксация гипотезы и допусков, получение и анализ результатов, сохранение артефактов. В блокноте также выполнен демонстрационный вариант 1 из методических указаний.

Приложение А. Ответы на вопросы для защиты

1. Для чего используется серия seed и почему изменяют только один фактор? При фиксированных прочих условиях влияние структуры запроса можно отделить от изменений параметров модели. Несколько seed позволяют оценить разброс результатов, зависящий от случайного начального шума.

2. Приведите пример расхождения критерия 2s и практического допуска. Для энергии границ изменение составляет -33,7%, что выходит за допуск ±10%, но отношение |Δ| / s = 1,25 меньше 2; значит, в этой серии эффект практически крупный, но не выходит за учебный порог разброса.

Источники

1. Лабораторная работа № 6. Исследование параметров text-to-image генерации. Методические указания по дисциплине «Искусственный интеллект в креативных технологиях», 2026.

2. Stability AI. SD Turbo: модель, исходные веса и документация. https://huggingface.co/stabilityai/sd-turbo

3. Stability AI Community License Agreement. https://huggingface.co/stabilityai/sd-turbo/blob/b261bac6fd2cf515557d5d0707481eafa0485ec2/LICENSE.md

4. OpenAI. CLIP ViT-B/32: карточка модели. https://huggingface.co/openai/clip-vit-base-patch32

5. Radford A. et al. Learning Transferable Visual Models From Natural Language Supervision. 2021. https://arxiv.org/abs/2103.00020